

Temat pracy dyplomowej inżynierskiej: "Tworzenie dokumentacji projektu z wykorzystaniem metod sztucznej inteligencji."

Celem tego projektu jest stworzenie inteligentnego systemu, który automatycznie generuje dokumentację dla API na podstawie kodu źródłowego oraz komentarzy zawartych w kodzie. Projekt będzie koncentrował się na generowaniu czytelnej dokumentacji technicznej oraz na personalizacji poziomu szczegółowości w zależności od potrzeb i poziomu doświadczenia użytkownika. Użytkownicy będą mogli przeglądać dokumentację przez intuicyjny interfejs i dostosować jej szczegółowość zgodnie ze swoimi preferencjami.

To właśnie etapy które chciałabym zrealizować w ramach tej pracy:

1. Analiza kodu i generowanie podstawowej dokumentacji

- Stworzenie parsera kodu, który będzie analizować kod źródłowy i identyfikować funkcje, klasy, endpointy itp.
- Integracja z systemem Swagger/OpenAPI do wygenerowania szkieletu dokumentacji na podstawie struktury kodu.

Rezultat: Podstawowa wersja dokumentacji API bez zaawansowanych opisów.

Zbudowałam pełną infrastrukturę backendową:

- java-api (Spring Boot) – serwer główny,
- python-nlp (FastAPI) – mikroservis do przetwarzania języka naturalnego,
- web (Nginx) – reverse proxy, łączący wszystko pod localhost:8080.

Stworzyłam system uploadu projektu (.zip):

- Endpoint `/api/projects/upload` rozpakowuje projekt i zapisuje go w `/uploads/<ID>`.
- Obsługa walidację, błędy i tworzy unikalny identyfikator projektu.

Dodałam detekcję pliku `openapi.yaml` lub `openapi.yml`:

Klasa `SpecDetector` analizuje strukturę ZIP i odnajduje specyfikację.

Jeśli spec nie istnieje, **system oferuje generację dokumentacji z kodu.**

Zintegrowałam system z OpenAPI / Swaggerem:

`EnrichmentService` potrafi wczytać istniejący `openapi.yaml` i wzbogacić go o opisy wygenerowane przez NLP.

Działa endpoint `/api/projects/{id}/spec/enriched`.

Dodałam parser kodu źródłowego (`JavaParser`):

`JavaSpringParser` analizuje pliki `.java`, wykrywa klasy z `@RestController`, ich metody i adnotacje (`@GetMapping`, `@PostMapping` itd.).

Tworzy pośrednią strukturę `EndpointIR`, która opisuje endpointy, parametry i typy zwracane.

Zbudowałam moduł „Code → OpenAPI”:

Klasa `CodeToDocsService` generuje kompletny plik `openapi.generated.yaml` na podstawie kodu źródłowego.

Integracja z NLP dodaje opis do każdej metody i parametru.

Dział endpoint `/api/projects/{id}/docs/from-code`.

2. Implementacja NLP do analizy komentarzy i generowania opisów

- Zastosowanie NLP do analizy komentarzy, aby tworzyć jasne, zrozumiałe opisy funkcji i parametrów.
- Użycie modeli NLP do interpretacji kontekstu i generowania opisów na podstawie komentarzy.

Rezultat: Automatycznie generowane, czytelne opisy dla każdej funkcji, co znacznie zwiększa czytelność dokumentacji.

Stworzyłam osobny mikroservis NLP (`python-nlp`), który:
przyjmuje strukturę endpointu (`symbol`, `comment`, `params`, `returns`),
analizuje komentarze i typy parametrów, generuje automatyczne opisy w trzech poziomach szczegółowości:

- `shortDescription`
- `mediumDescription`
- `longDescription`
- dodaje także `paramDocs` (opis każdego parametru) i `returnDoc`.

Zintegrowałam NLP z backendem (`Spring Boot`):

- `EnrichmentService` wysyła do `/nlp/describe` dane z kodu i odbiera opisy.
- Wyniki są automatycznie wstawiane do dokumentacji OpenAPI lub pliku YAML.

Zaimplementowałam personalizowany poziom szczegółowości (`short/medium/long`):
Użytkownik może wybrać poziom, a system automatycznie dopasowuje długość i szczegółowość opisów.

3. Stworzenie systemu personalizacji dokumentacji

Umożliwiłam ręczny wybór poziomu szczegółowości dokumentacji (`short`, `medium`, `long`) – użytkownik decyduje, jak rozbudowane mają być opisy.

- Implementacja mechanizmów śledzenia interakcji użytkownika, aby rozpoznać wzorce zachowań. (Śledzenie kliknięć i wyborów, czas spędzony na poszczególnych sekcjach, śledzenie wyszukiwań, interakcje z poziomem szczegółowości)
- Zastosowanie uczenia maszynowego do klasyfikacji użytkowników jako początkujących lub zaawansowanych.
- Tworzenie personalizowanych wersji dokumentacji, w zależności od poziomu doświadczenia użytkownika.

Rezultat: Dokumentacja dostosowana do poziomu wiedzy użytkownika, z możliwością wyboru poziomu szczegółowości.

4. Budowa interaktywnego interfejsu użytkownika

- Stworzenie dynamicznego interfejsu użytkownika, który umożliwia przeglądanie dokumentacji, filtrowanie i przeszukiwanie.
- Integracja interfejsu z backendem oraz systemem personalizacji.

Rezultat: Funkcjonalny interfejs użytkownika, który umożliwia wygodne przeglądanie dokumentacji i dostosowywanie poziomu szczegółowości.

5. Testowanie i optymalizacja

- Przeprowadzenie testów użyteczności i optymalizacji pod kątem wydajności.
- Testowanie algorytmów personalizacji i dopasowywanie ich do realnych potrzeb użytkowników.

Rezultat: Stabilna i zoptymalizowana wersja systemu gotowa do wdrożenia.

07.10.2025:

Java: Spring Boot, springdoc-openapi

Python: FastAPI, do NLP: spaCy / Hugging Face

Frontend: React + TypeScript

Wspólne: Docker

Co działa teraz:

- java-api - serwis backendowy (Spring Boot),
- python-nlp - mikroserwis AI (FastAPI),
- web - serwer Nginx (reverse proxy), który spina wszystko razem i wystawia publiczny adres <http://localhost:8080>.

1. Środowisko uruchomieniowe (Docker + Nginx)

- Trzy serwisy odpalane razem: java-api (Spring Boot), python-nlp (FastAPI), web (Nginx reverse proxy).
- Jeden punkt dostępu: <http://localhost:8080> (Nginx przekazuje /api, /v3, /swagger-ui, /nlp do właściwych serwisów).

2. Java API – szkielety i dokumentacja

- springdoc-openapi podłączony: automatyczna specyfikacja OpenAPI: /v3/api-docs (JSON), /v3/api-docs.yaml (YAML),
- Swagger UI: /swagger-ui/index.html.
- OpenApiConfig: ładny tytuł, opis, contact, license (MIT)

Endpoints demo (do dokumentowania i testów)

- GET /api/hello?name=: szybki test.
- GET /api/users/{id}: przykładowy odczyt (DTO w odpowiedzi).
- POST /api/users (JSON body + walidacja): pełny przepływ request body: response:
- 400 Bad Request z czytelnymi błędami walidacji, gdy dane są niepełne.

Java API będzie wysyłać surowe dane (nazwy funkcji, parametry, komentarze) do serwisu python-nlp, żeby otrzymać opisy w języku naturalnym.

3. Python NLP – gotowy mikroserwis

- GET /nlp/healthz (przez Nginx jako /nlp/healthz) — healthcheck.
- POST /nlp/describe — zwraca short/medium/long (szkielet pod późniejsze NLP).
- Nginx ma poprawne proxy dla /nlp/*, więc UI/Java mogą go wołać bez CORS.

• Java API będzie wysyłać do niego „surowe dane z parsera” (nazwy metod, komentarze),

- on będzie zwracał czytelne opisy,
- dane te trafiają z powrotem do dokumentacji OpenAPI.

Pliki/elementy, które powstały:

- java-api/pom.xml — zależności: springdoc-openapi-starter-webmvc-ui, walidacja.
- java-api/src/main/java/.../config/OpenApiConfig.java — tytuł/opis/contact/license.
- java-api/src/main/java/.../controller/HelloController.java — prosty endpoint.
- java-api/src/main/java/.../controller/UsersController.java — GET/POST z JSON body.
- java-api/src/main/java/.../dto/CreateUserRequest.java i UserResponse.java — DTO (walidacja + schematy w OpenAPI).
- web-ui/nginx.conf — proxy do /api, /v3, /swagger-ui, /nlp.
- docker-compose.yml — definicje trzech kontenerów i ich sieci.

Zastosowany mikroserwis python-nlp będzie wykorzystywać model językowy mT5 (Multilingual Text-to-Text Transfer Transformer), opracowany przez Google Research.

Model ten przetwarza dane wejściowe w postaci komentarzy i nazw metod, a następnie generuje opisy w języku naturalnym w kilku wariantach (krótki, średni, szczegółowy).

Dzięki temu możliwe jest tworzenie dokumentacji technicznej opartej na kodzie źródłowym w sposób zautomatyzowany i inteligentny, bez konieczności pisania tekstów przez człowieka.

Test	Heurystyki (bez AI)	NLP (z AI)
GET /api/users/{id}	„Zwraca zasób po ID.”	„Zwraca użytkownika o podanym identyfikatorze. Jeśli nie istnieje, zwraca 404.”
POST /api/users	„Tworzy nowy zasób.”	Tworzy nowego użytkownika z danymi name i ↓ i1, walidując poprawność adresu e-mail.”

google/mt5-small

Co się dzieje pod spodem:

1. Plik trafia do backendu (java-api - / api/upload).
2. Mój system rozpakowuje ZIP-a, analizuje kod:
 - wykrywa klasy, kontrolery, funkcje, parametry, adnotacje, komentarze;
 - tworzy surowy opis kodu.

3. Dla każdego endpointu (np. GET /api/users/{id}) wysyła zapytanie do mikroserwisu python-nlp, który analizuje komentarze i generuje teksty opisowe (short, medium, long).

Swagger daje strukturę, a NLP daje semantykę i naturalny język

Przed: surowe dane

```
/api/hello:  
  get:  
    responses:  
      "200":  
        description: OK
```

Po:

```
/api/hello:  
  get:  
    summary: Zwraca powitanie użytkownika.  
    description: Endpoint zwraca powitanie z imieniem przekazanym w parametrze  
    `name`.  
    responses:  
      "200":  
        description: Poprawna odpowiedź z wiadomością powitalną.
```

14.10.2025:

2. Implementacja NLP do analizy opisów w specyfikacji OpenAPI i generowania rozszerzonej dokumentacji

W ramach tego etapu wdrożono mikroserwis NLP, który analizuje istniejące opisy i komentarze w pliku OpenAPI (openapi.yaml) oraz automatycznie generuje bardziej rozbudowane, naturalne i zrozumiałe opisy funkcji, parametrów i odpowiedzi.

W odróżnieniu od klasycznego podejścia, gdzie analiza odbywa się bezpośrednio na kodzie źródłowym, system wykorzystuje strukturę OpenAPI jako pośrednią warstwę semantyczną. Dzięki temu możliwe jest automatyczne wzbogacanie dokumentacji wygenerowanej z dowolnego projektu zawierającego specyfikację API, niezależnie od języka programowania.

Mikroserwis NLP, oparty na frameworku FastAPI i modelach językowych, generuje opisy w trzech poziomach szczegółowości (short, medium, long). Wyniki są automatycznie wstawiane do sekcji description w obiektach paths, parameters i responses specyfikacji OpenAPI.

Rezultat: dokumentacja API staje się pełniejsza, spójna i bardziej zrozumiała dla użytkownika końcowego, bez konieczności ręcznego uzupełniania opisów w kodzie.

Do 21.10:

Następnym krokiem w rozwoju systemu będzie

1. **dodanie pełnej obsługi generowania dokumentacji na podstawie kodu źródłowego i komentarzy w kodzie – w sytuacji, gdy projekt nie zawiera pliku openapi.yaml.**

Jeśli użytkownik wgra projekt bez gotowej specyfikacji OpenAPI, system:

- automatycznie wykryje brak pliku openapi.yaml,
- przeanalizuje kod źródłowy (Java, a w przyszłości także Python),
- odczyta komentarze, typy danych i endpointy,
- wygeneruje kompletną dokumentację API przy użyciu NLP,
- zapisując ją jako openapi.generated.yaml.

Dzięki temu użytkownik nie musi samodzielnie pisać pliku OpenAPI, dokumentacja zostanie stworzona na podstawie kodu i komentarzy.

UPDATE 18.10.25:

Co zostało zrobione:

Zaimplementowałam mechanizm automatycznego generowania dokumentacji API w formacie OpenAPI na podstawie kodu źródłowego projektu (Java) w sytuacji, gdy użytkownik nie dostarcza własnego pliku openapi.yaml.

System analizuje kod, odczytuje komentarze (Javadoc), typy danych oraz adnotacje kontrolerów Springa, a następnie generuje kompletny plik openapi.generated.yaml.

Jak to działa:

1. Użytkownik wysyła projekt jako archiwum ZIP.
2. System sprawdza, czy w projekcie znajduje się plik openapi.yaml. Jeśli go brak — uruchamiany jest moduł Code -> OpenAPI.
3. Klasa JavaSpringParser analizuje wszystkie pliki .java:
 - wykrywa klasy oznaczone adnotacjami @RestController lub @Controller,
 - rozpoznaje metody z adnotacjami @GetMapping, @PostMapping, @RequestMapping itd.,
 - odczytuje ścieżki, typy metod HTTP, parametry oraz komentarze Javadoc (@param, @return).

Wynik zapisywany jest jako struktura pośrednia EndpointIR.

4. Klasa CodeToDocsService przetwarza te dane i generuje gotową specyfikację OpenAPI 3.0:

- dodaje sekcje paths, parameters, requestBody, responses,
- uzupełnia opisy metod i parametrów przy pomocy NLP,
- zapisuje wynik jako plik openapi.generated.yaml.

5. Użytkownik może pobrać wygenerowany plik.

Efekt: Dzięki temu system automatycznie tworzy pełną dokumentację API nawet wtedy, gdy projekt nie zawiera gotowego pliku openapi.yaml. Użytkownik nie musi jej pisać ręcznie — dokumentacja jest generowana dynamicznie na podstawie kodu i komentarzy.

openapi: 3.0.1

info:

title: Project bb587ae5001842b3aa59a8623c9ee7a8-API

version: 1.0.0

paths:

/@GetMapping("/hello"):

get:

summary: "Zwraca obiekt `Map<String,String>`. Typowe kody odpowiedzi: 200."

description: "Zwraca obiekt `Map<String,String>`. Typowe kody odpowiedzi: 200."

operationId: HelloController_hello

parameters:

- *name:* name

in: query

description: Parametr name.

required: **false**

schema:

type: string

responses:

"200":

description: "Zwraca obiekt `Map<String,String>`."

content:

application/json:

schema:

type: object

/@RequestMapping("/api/orders")/@GetMapping("/{id}"):

get:

summary: "Pobiera zamówienie po ID. Typowe kody odpowiedzi: 200."

description: "Pobiera zamówienie po ID. Typowe kody odpowiedzi: 200."

operationId: OrderController_getOrder

parameters:

- *name:* id

in: path

description: Identyfikator zamówienia.

required: **true**

schema:

type: string

responses:

"200":

description: Zwraca obiekt `Object`.

content:

application/json:

schema:

type: object

/@RequestMapping("/api/orders")/id:

delete:

summary: "Usuwa zamówienie (przykład użycia RequestMapping z metodą). Typowe kody odpowiedzi: 200."

description: "Usuwa zamówienie (przykład użycia RequestMapping z metodą). Typowe kody odpowiedzi: 200."

operationId: OrderController_delete

parameters:

- *name:* id

in: path

description: Identyfikator zamówienia.

required: **true**

schema:

type: string

responses:

"200":

description: Zwraca obiekt `Object`.

content:

application/json:

schema:

type: object

/@RequestMapping("/api/orders")/@PostMapping("/orderId/items"):

post:

summary: "Dodaje pozycję do zamówienia. Typowe kody odpowiedzi: 200."

description: "Dodaje pozycję do zamówienia. Typowe kody odpowiedzi: 200."

operationId: OrderController_addItem

parameters:

- *name:* orderId

in: path

description: Identyfikator zamówienia.

required: **true**

schema:

type: string

- *name:* sku

in: query

description: Kod produktu.

required: **false**

schema:

type: string


```
- name: qty
  in: query
  description: Ilość.
  required: false
  schema:
    type: integer
    format: int32
responses:
  "200":
    description: Zwraca obiekt `Object`.
    content:
      application/json:
        schema:
          type: object
/@@RequestMapping("/api/users")/@GetMapping("/{id}"):
get:
  summary: "Zwraca użytkownika po ID. Typowe kody odpowiedzi: 200."
  description: "Zwraca użytkownika po ID. Typowe kody odpowiedzi: 200."
  operationId: UserController_getById
  parameters:
    - name: id
      in: path
      description: Identyfikator użytkownika.
      required: true
      schema:
        type: string
responses:
  "200":
    description: Zwraca obiekt `UserResponse`.
    content:
      application/json:
        schema:
          type: object
/@@RequestMapping("/api/users")/:
get:
  summary: "Wyszukuje użytkowników. Typowe kody odpowiedzi: 200."
  description: "Wyszukuje użytkowników. Typowe kody odpowiedzi: 200."
  operationId: UserController_search
  parameters:
    - name: q
```

in: query

description: Fraza wyszukiwania.

required: **false**

schema:

type: string

- *name:* page

in: query

description: Numer strony.

required: **false**

schema:

type: integer

format: int32

- *name:* size

in: query

description: Rozmiar strony.

required: **false**

schema:

type: integer

format: int32

responses:

"200":

description: Zwraca obiekt `Object`.

content:

application/json:

schema:

type: object

post:

summary: "Tworzy nowego użytkownika. Typowe kody odpowiedzi: 200, 400, 409."

description: "Tworzy nowego użytkownika. Typowe kody odpowiedzi: 200, 400, 409."

operationId: UserController_create

requestBody:

description: Dane użytkownika.

content:

application/json:

schema:

type: object

required: **true**

responses:

"200":

description: Zwraca obiekt `UserResponse`.

```
content:
  application/json:
    schema:
      type: object
```

Dodać:

Dodać prosty parser klas DTO.

Wydobyć z każdej klasy pola (String name, int age, itp.) i dodać je do components/schemas.

Zamiast schema: object używać \$ref: '#/components/schemas/NazwaKlasy'.

2. wdrożenie modelu mT5 (text-to-text) do inteligentnego generowania dokumentacji

- Integracja modelu mT5 w mikroserwisie python-nlp przy użyciu biblioteki transformers (Hugging Face).
- Model mT5 będzie przetwarzać dane w formacie:

Wejście:

"Komentarz: Zwraca użytkownika po ID. Parametr: id - identyfikator użytkownika."

Wyjście:

"Endpoint służy do pobierania danych użytkownika na podstawie jego identyfikatora. Jeśli użytkownik nie zostanie znaleziony, zwracany jest kod 404."

3. Gotowy harmonogram Pracy Inżynierskiej

Do 28.10: